Python内置数据结构

讲师：Wayne

从业十余载，漫漫求知路

集set

- 约定
  - set 翻译为集合
  - collection 翻译为集合类型，是一个大概念
- set
  - **可变的**、**无序的**、**不重复**的元素的集合

set定义 初始化

- set() -> new empty set object
- set(iterable) -> new set object

```
s1 = set()
s2 = set(range(5))
s3 = set(list(range(10)))
s4 = {} # ?
s5 = {9,10,11} # set
s6 = {(1,2),3,'a'}
s7 = {[1],(1,),1} # ?
```

set的元素

- set的元素要求必须可以hash
- 目前学过的不可hash的类型有list、set
- 元素不可以使用索引
- set可以迭代

set增加

- add(elem)
  - 增加一个元素到set中
  - 如果元素存在，什么都不做
- update(*others)
  - 合并其他元素到set集合中来
  - 参数others必须是可迭代对象
  - 就地修改

set删除

- remove(elem)
  - 从set中移除一个元素
  - 元素不存在，抛出KeyError异常。为什么是KeyError？
- discard(elem)
  - 从set中移除一个元素
  - 元素不存在，什么都不做
- pop() -> item
  - 移除并返回任意的元素。为什么是任意元素？
  - 空集返回KeyError异常
- clear()
  - 移除所有元素

set修改、查询

- 修改
  - 要么删除，要么加入新的元素
  - 为什么没有修改？
- 查询
  - 非线性结构，无法索引
- 遍历
  - 可以迭代所有元素

- 成员运算符
  - in 和 not in 判断元素是否在set中
  - 效率呢？

set成员运算符的比较

- list和set的比较
- lst1 = list(range(100))
- lst2 = list(range(1000000))
- -1 in lst1、-1 in lst2 看看效率
- set1 = set(range(100))
- set2 = set(range(1000000))
- -1 in set1、-1 in set2 看看效率

set成员运算符的比较

```
%%timeit lst1=list(range(100))
a = -1 in lst1
```

```
1.22 µs ± 4.67 ns per loop (mean ± std. dev. of 7 runs, 1000000 loops each)
```

```
%%timeit lst1=list(range(1000000))
a = -1 in lst1
```

```
12 ms ± 116 µs per loop (mean ± std. dev. of 7 runs, 100 loops each)
```

```
%%timeit set1=set(range(100))
a = -1 in set1
```

```
32 ns ± 0.141 ns per loop (mean ± std. dev. of 7 runs, 10000000 loops each)
```

```
%%timeit set1=set(range(1000000))
a = -1 in set1
```

```
32.3 ns ± 0.0916 ns per loop (mean ± std. dev. of 7 runs, 10000000 loops each)
```

set和线性结构

- 线性结构的查询时间复杂度是O(n)，即随着数据规模的增大而增加耗时
- set、dict等结构，内部使用hash值作为key，时间复杂度可以做到O(1)，查询时间和数据规模无关

- 可hash
  - 数值型int、float、complex
  - 布尔型True、False
  - 字符串string、bytes
  - tuple
  - None
  - 以上都是不可变类型，是可哈希类型，hashable

- set的元素必须是可hash的

集合

- 基本概念
  - 全集
    - 所有元素的集合。例如实数集，所有实数组成的集合就是全集
  - 子集subset和超集superset
    - 一个集合A所有元素都在另一个集合B内，A是B的子集，B是A的超集
  - 真子集和真超集
    - A是B的子集，且A不等于B，A就是B的真子集，B是A的真超集
  - 并集：多个集合合并的结果
  - 交集：多个集合的公共部分
  - 差集：集合中除去和其他集合公共部分

集合运算

- 并集
  - 将两个集合A和B的所有的元素合并到一起，组成的集合称作集合A与集合B的并集
  - union(*others)
    - 返回和多个集合合并后的新的集合
  - | 运算符重载
    - 等同union
  - update(*others)
    - 和多个集合合并，就地修改
  - |=
    - 等同update

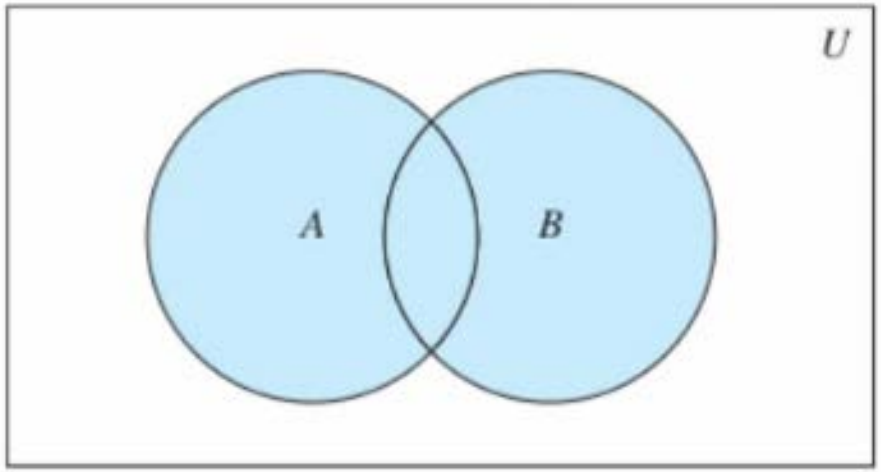

集合运算

- 交集
  - 集合A和B，由所有属于A且属于B的元素组成的集合
  - intersection(*others)
    - 返回和多个集合的交集
  - &
    - 等同intersection
  - intersection_update(*others)
    - 获取和多个集合的交集，并就地修改
  - &=
    - 等同intersection_update

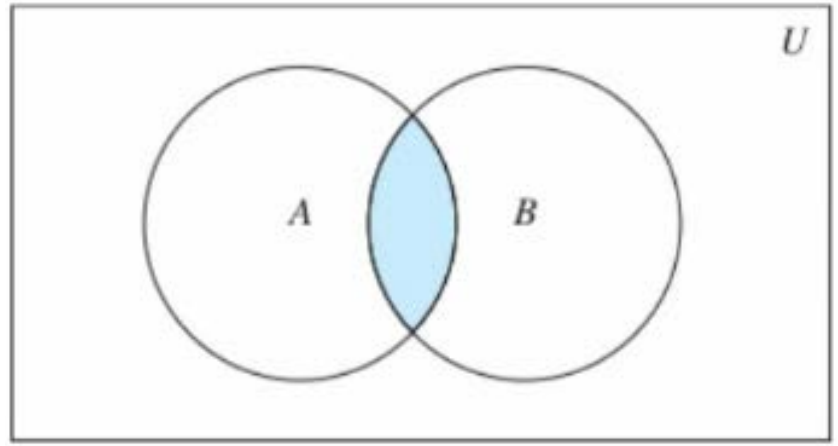

集合运算

- 差集
  - 集合A和B，由所有属于A且不属于B的元素组成的集合
  - difference(*others)
    - 返回和多个集合的差集
  - -
    - 等同difference
  - difference_update(*others)
    - 获取和多个集合的差集并就地修改
  - -=
    - 等同difference_update

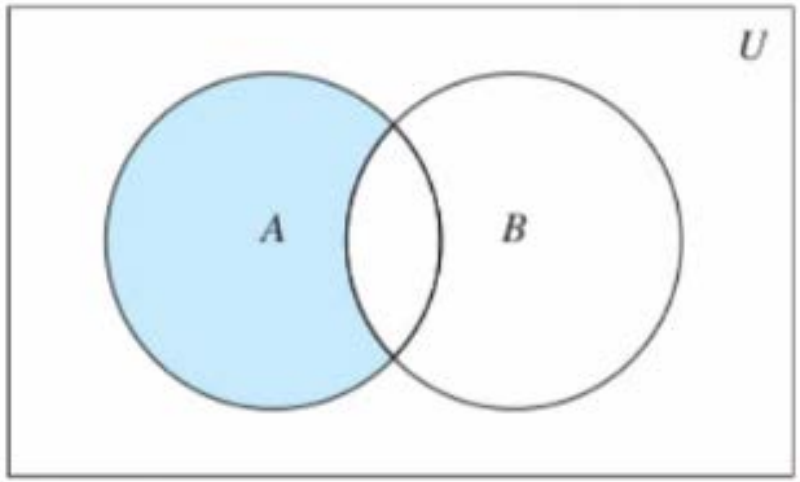

集合运算

- 对称差集
  - 集合A和B，由所有不属于A和B的交集元素组成的集合，记作（A-B）∪（B-A）
  - symmetric_differece(other)
    - 返回和另一个集合的差集
  - ^
    - 等同symmetric_differece
  - symmetric_differece_update(other)
    - 获取和另一个集合的差集并就地修改
  - ^=
    - 等同symmetric_differece_update

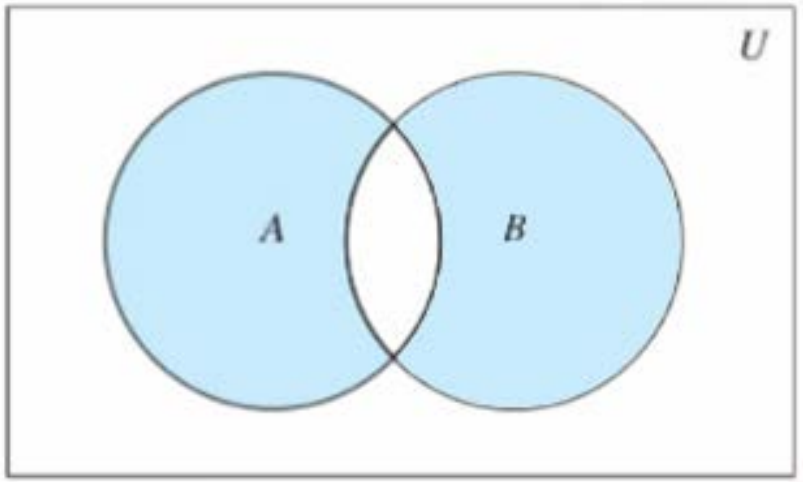

集合运算

- issubset(other)、<=
  - 判断当前集合是否是另一个集合的子集
- set1 < set2
  - 判断set1是否是set2的真子集
- issuperset(other)、>=
  - 判断当前集合是否是other的超集
- set1 > set2
  - 判断set1是否是set2的真超集
- isdisjoint(other)
  - 当前集合和另一个集合没有交集
  - 没有交集，返回True

集合应用

- 共同好友
  - 你的好友A、B、C，他的好友C、B、D，求共同好友
- 微信群提醒
  - XXX与群里其他人都不是微信朋友关系
- 权限判断
  - 有一个API，要求权限同时具备A、B、C才能访问，用户权限是B、C、D，判断用户是否能够访问该API
  - 有一个API，要求权限具备A、B、C任意一项就可访问，用户权限是B、C、D，判断用户是否能够访问该API
- 一个总任务列表，存储所有任务。一个完成的任务列表。找出为未完成的任务

集合应用

- 共同好友
  - 你的好友A、B、C，他的好友C、B、D，求共同好友
  - 交集问题：{'A', 'B', 'C'}.intersection({'B', 'C', 'D'})
- 微信群提醒
  - X与群里其他人都不是微信朋友关系
  - 并集：userid in (A | B | C | ...) == False，A、B、C等是微信好友的并集，用户ID不在这个并集中，说明他和任何人都不是朋友
  - 群里所有其他人IDs都不在X的朋友列表T中 T & IDs == set()

集合应用

- 权限判断
  - 有一个API，要求权限同时具备A、B、C才能访问，用户权限是B、C、D，判断用户是否能够访问该API
    - API集合A，权限集合P。要用户权限全部包含API权限要求。
    - A - P = set() ，A-P为空集，说明P包含A
    - A.issubset(P) 也行，A是P的子集也行
    - A & P = A 也行
  - 有一个API，要求权限具备A、B、C任意一项就可访问，用户权限是B、C、D，判断用户是否能够访问该API
    - API集合A，权限集合P
    - A & P != set() 就可以
    - A.isdisjoint(P) == False 表示有交集

集合应用

- 一个总任务列表，存储所有任务。一个已完成的任务列表。找出为未完成的任务
  - 业务中，任务ID一般不可以重复
  - 所有任务ID放到一个set中，假设为ALL
  - 所有已完成的任务ID放到一个set中，假设为COMPLETED，它是ALL的子集
  - ALL - COMPLETED = UNCOMPLETED

集合练习

- 随机产生2组各10个数字的列表，如下要求：
  - 每个数字取值范围[10,20]
  - 统计20个数字中，一共有多少个不同的数字？
  - 2组之间进行比较，不同的数字有几个？分别是什么？
  - 2组之间进行比较，相同的数字有几个？分别是什么？

a = [1, 9, 7, 5, 6, 7, 8, 8, 2, 6]
b = [1, 9, 0, 5, 6, 4, 8, 3, 2, 3]

集合练习

- 随机产生2组各10个数字的列表，如下要求：
  - 每个数字取值范围[10,20]
  - 统计20个数字中，一共有多少个不同的数字？
  - 2组之间进行比较，不同的数字有几个？分别是什么？
  - 2组之间进行比较，相同的数字有几个？分别是什么？

```
a = [1, 9, 7, 5, 6, 7, 8, 8, 2, 6]
b = [1, 9, 0, 5, 6, 4, 8, 3, 2, 3]
s1 = set(a)
s2 = set(b)
print(s1)
print(s2)
print(s1.union(s2))
print(s1.symmetric_difference(s2))
print(s1.intersection(s2))
```

谢谢

咨询热线 400-080-6560